SMART FARMING DASHBOARD DARI SENSOR IOT

Dataset 1 : Smart Farming Sensor Data

Big Data dan IOT

DOSEN PENGAMPU :

Dr. Eng. Agussalim, S.Pd., M.T.

DISUSUN OLEH :

Rania Nurbaity Winarno (23082010134)

PROGRAM STUDI SISTEM INFORMASI

FAKULTAS ILMU KOMPUTER

UNIVERSITAS PEMBANGUNAN NASIONAL "VETERAN" JAWA TIMUR

SURABAYA

2026

A. DATASET

Dataset diambil dari kaggle dengan nama “Smart Farming Sensor Data for Yield Prediction” dengan link dataset : 🌾 Smart Farming Sensor Data for Yield Prediction
Terdapat 22 kolom dengan 500 baris data

B. DATA ACQUISITION

```
import kagglehub

path = kagglehub.dataset_download("atharvasoundankar/smart-farming-sensor-data-for-yield-prediction")

print("Path to dataset files:", path)
```

```
Warning: Looks like you're using an outdated `kagglehub` version (installed: 0.3.13), please consider upgrading to the latest version (1.0.0).
Downloading from https://www.kaggle.com/api/v1/datasets/download/atharvasoundankar/smart-farming-sensor-data-for-yield-prediction?dataset_version_number=1..
100%|██████████| 27.7k/27.7k [00:00<00:00, 34.1MB/s]Extracting files...
Path to dataset files: /root/.cache/kagglehub/datasets/atharvasoundankar/smart-farming-sensor-data-for-yield-prediction/versions/1
```

Dataset di download via kagglehub dan hasilnya disalin ke folder data/raw sebagai acuan data mentah. Setelah berhasil. dataset tersebut akan dipakai untuk processing data. Dalam dataset ini, terdapat 22 kolom yang tertera seperti pada gambar berikut

	farm_id	region	crop_type	soil_moisture_%	soil_pH	temperature_C	rainfall_mm	humidity_%	sunlight_hours	irrigation_type	...	sowing_date	harvest_date	total_days	yield_kg_per_hectare	sensor_id	timestamp	la
0	FARM0001	North India	Wheat	35.95	5.99	17.79	75.62	77.03	7.27	NaN	...	2024-01-08	2024-05-09	122	4408.07	SENS0001	2024-03-19	14.9
1	FARM0002	South USA	Soybean	19.74	7.24	30.18	89.91	61.13	5.67	Sprinkler	...	2024-02-04	2024-05-26	112	5389.98	SENS0002	2024-04-21	16.6
2	FARM0003	South USA	Wheat	29.32	7.16	27.37	265.43	68.87	8.23	Drip	...	2024-02-03	2024-06-26	144	2931.16	SENS0003	2024-02-28	19.5
3	FARM0004	Central USA	Maize	17.33	6.03	33.73	212.01	70.46	5.03	Sprinkler	...	2024-02-21	2024-07-04	134	4227.80	SENS0004	2024-05-14	31.0
4	FARM0005	Central USA	Cotton	19.37	5.92	33.86	269.09	55.73	7.93	NaN	...	2024-02-05	2024-05-20	105	4979.96	SENS0005	2024-04-13	16.5

5 rows × 22 columns

Beberapa kolom yang paling penting diantaranya : timestamp. soil_moisture_%, temperature C, dan humidity_%. Dan pada gambar tersebut, menampilkan 5 baris awal dari dataset yang akan diolah nantinya.

C. DATA PROCESSING

a. EDA

- df.info()

  Digunakan untuk mengetahui nama kolom, jumlah kolom terisi, dan tipe data setiap kolom seperti pada gambar berikut

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 500 entries, 0 to 499
Data columns (total 22 columns):
 #   Column                Non-Null Count  Dtype
---  ------                --------------  -----
 0   farm_id               500 non-null    object
 1   region                500 non-null    object
 2   crop_type             500 non-null    object
 3   soil_moisture_%       500 non-null    float64
 4   soil_pH               500 non-null    float64
 5   temperature_C         500 non-null    float64
 6   rainfall_mm           500 non-null    float64
 7   humidity_%            500 non-null    float64
 8   sunlight_hours        500 non-null    float64
 9   irrigation_type       350 non-null    object
 10  fertilizer_type       500 non-null    object
 11  pesticide_usage_ml    500 non-null    float64
 12  sowing_date           500 non-null    object
 13  harvest_date          500 non-null    object
 14  total_days            500 non-null    int64
 15  yield_kg_per_hectare  500 non-null    float64
 16  sensor_id             500 non-null    object
 17  timestamp             500 non-null    object
 18  latitude              500 non-null    float64
 19  longitude             500 non-null    float64
 20  NDVI_index            500 non-null    float64
 21  crop_disease_status   370 non-null    object
dtypes: float64(11), int64(1), object(10)
memory usage: 86.1+ KB
```

- df.describe()

  Digunakan untuk menampilkan ringkasan statistik, seperti pada gambar

	soil_moisture_%	soil_pH	temperature_C	rainfall_mm	humidity_%	sunlight_hours	pesticide_usage_ml	total_days	yield_kg_per_hectare	latitude	longitude	NDVI_inde
count	500.000000	500.000000	500.000000	500.000000	500.000000	500.00000	500.000000	500.000000	500.00000	500.000000	500.000000	500.00000
mean	26.750140	6.523980	24.675740	181.685740	65.194460	7.03014	26.586980	119.496000	4032.92694	22.442473	80.392248	0.602060
std	10.150053	0.585558	5.348899	72.293091	14.642849	1.69167	13.202429	16.798046	1174.43304	7.283492	5.910664	0.175400
min	10.160000	5.510000	15.000000	50.170000	40.230000	4.01000	5.050000	90.000000	2023.56000	10.004243	70.020021	0.300000
25%	17.890000	6.030000	20.295000	119.217500	51.805000	5.66750	14.945000	105.750000	2994.82000	16.263202	75.374713	0.447500
50%	25.855000	6.530000	24.655000	191.545000	65.685000	6.99500	25.980000	119.000000	4071.69000	21.981743	80.650284	0.610000
75%	36.022500	7.040000	29.090000	239.035000	77.995000	8.47000	38.005000	134.000000	5062.11000	28.528948	85.654629	0.750000
max	44.980000	7.500000	34.840000	298.960000	90.000000	10.00000	49.940000	150.000000	5998.29000	34.981531	89.991901	0.900000

dari gambar tersebut kita bisa mengetahui jumlah data, rata rata, nilai minimum dan nilai maksimum dari setiap kolom

- df.isnull().sum()

	0
farm_id	0
region	0
crop_type	0
soil_moisture_%	0
soil_pH	0
temperature_C	0
rainfall_mm	0
humidity_%	0
sunlight_hours	0
irrigation_type	150

Digunakan untuk mengetahui jumlah nilai kosong disetiap kolom. Misalnya, dari gambar tersebut berarti pada kolom irrigation_type, terdapat 150 nilai kosong

b. Data Cleaning

Hal ini dilakukan untuk mengatasi *missing value*, menangani *outlier* ataupun membuat format data menjadi sama antar satu sama lain

```
#Handling mv
df = df.fillna(df.median(numeric_only=True))
```

```
#Convert Timestamp
df['timestamp'] = pd.to_datetime(df['timestamp'])
```

```
#Remove outlier - IQR
numeric_cols = df.select_dtypes(include=['number']).columns

Q1 = df[numeric_cols].quantile(0.25)
Q3 = df[numeric_cols].quantile(0.75)
IQR = Q3 - Q1

# For each numeric column, check if values are outside the IQR range
outlier_mask = ((df[numeric_cols] < (Q1 - 1.5 * IQR)) | (df[numeric_cols] > (Q3 + 1.5 * IQR))).any(axis=1)

# Filter the DataFrame to remove rows with outliers
df = df[~outlier_mask]

df['irrigation_type'] = df['irrigation_type'].fillna(df['irrigation_type'].mode()[0])
df['crop_disease_status'] = df['crop_disease_status'].fillna(df['crop_disease_status'].mode()[0])
df['sowing_date'] = pd.to_datetime(df['sowing_date'])
df['harvest_date'] = pd.to_datetime(df['harvest_date'])
```

Dari gambar tersebut, yang dilakukan pertama adalah mengisi nilaikosong pada kolom yang bersifat numerik dengan median untuk mencegah data kosong. Lalu, mengubah format pada kolom timestamp menjadi datetime supaya dapat dianalisis ataupun memuat grafik yang menggunakan waktu

Lalu, mencoba menghilangkan outlier dari kolom yang bersifat numerik dengan IQR. Setelah itu, untuk menghilangkan *missing value* pada kolom kategorikal,digunakan dengan mode atau nilai yang paling sering muncul. Dan yang terakhir, mengubah format pada kolom tanggal tanam dan panen ke format datetime,

D. DATA ANALYSIS

a. Correlation Heatmap

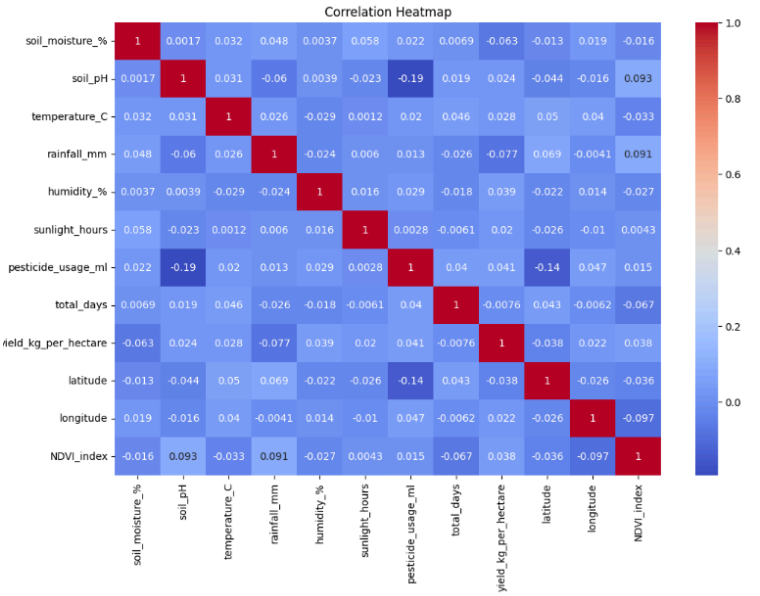

Berdasarkan heatmap diatas, angka yang tertera adalah sekitar 0.00 - 0.006 dengan warna yang hampir semua merupakan biru muda. Maka dari itu, artinya hampir tidak ada variabel yang saling mempengaruhi. Yang paling menonjol walaupun sangat kecil adalah seputar pestisida dengan kondisi tanah (-0.19). Hal tersebut menunjukkan bahwa semakin banyak pestisida yang dipakai, pH tanah cenderung menurun. Hal ini mungkin terjadi karena dataset bersifat simulasi sehingga model yang dibuat mungkin kurang akurat nantinya

b. Timeseries Trend

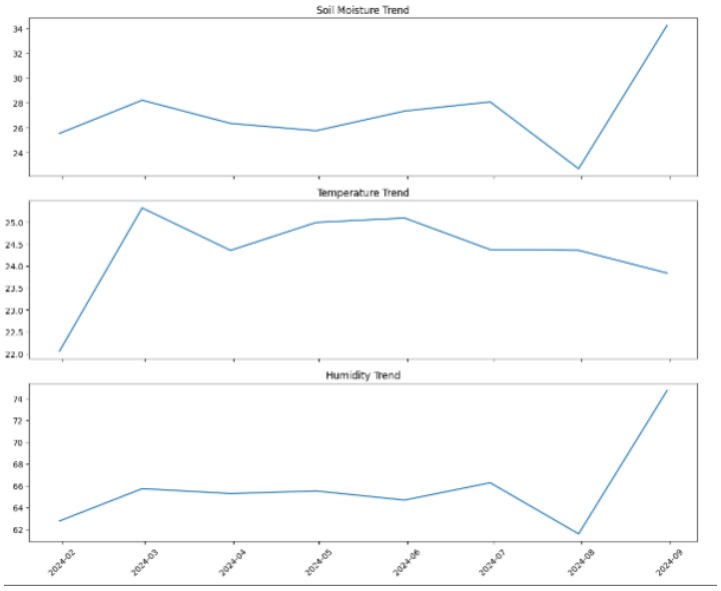

Dalam timeseries tren, terdapat 3 hal yang dapat dilihat, diantaranya :

1. Kelembaban tanah : Kenaikan cenderung stabil tetapi ada lonjakan tajam dibulan agustus

2. Suhu : Kenaikan tajam pada bulan februari - maret, bulan selanjurnya lebih stabil
3. Kelembaban Udara : Pada bulan Januari - Juli cenderung stabil, tetapi ada kenaikan drastis di bulan agustus

E. VISUALIZATION & DASHBOARD

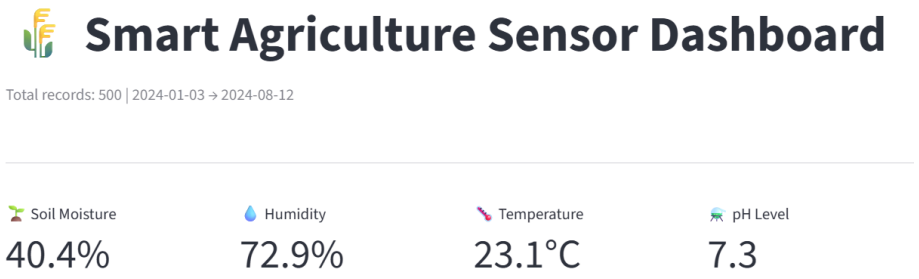

Bagian awal menampilkan judul dashboard dan menampilkan 4 nilai, yaitu Kelembaban tanah, Udara, Suhu dan nilai pH.

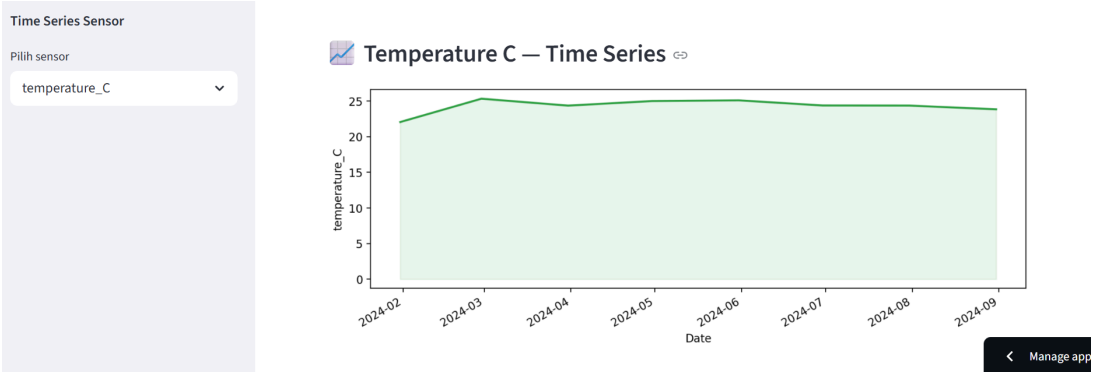

Selanjutnya terdapat grafik timeseries yang bisa dilihat berdasarkan sensor yang dipilih pada sidebar disebelah kiri

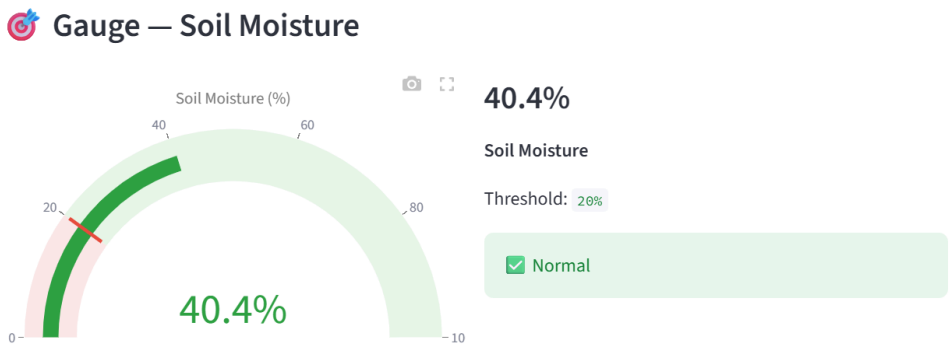

Menampilkan tingkat kelembabapan tanah dalam bentuk setengah lingkaran dengan area merah merupakan area yang berbahaya, sementara area hijau menandakan kondisi aman.

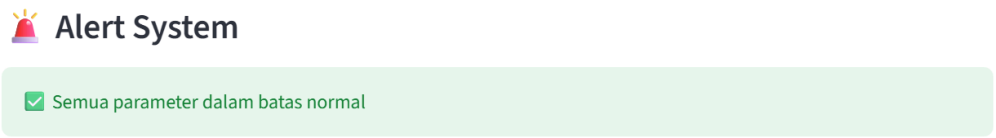

Lalu terdapat alert sistem yang menunjukkan bahwa seluruh parameter dalam kondisi aman yang ditandai dengan warna hijau.

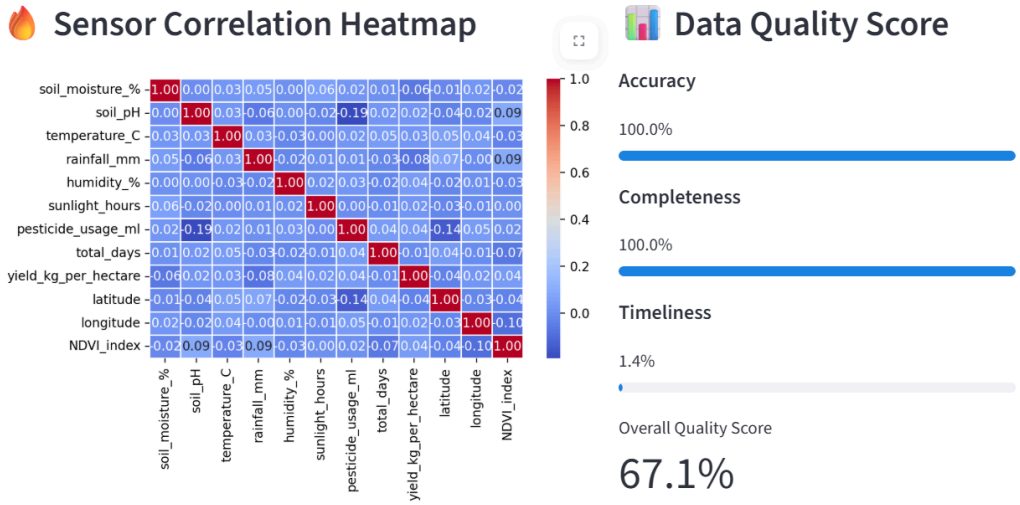

Dan yang terakhir ada sebaran korelasi antar sensor dalam hearmap dan kualitas data yang dihasilkan

F. DATA GOVERNANCE & QUALITY SCORE

Seperti yang tertera pada dashboard bagian akhir, berikut adalah skor kualitas dari data yang ada, seperti gambar berikut

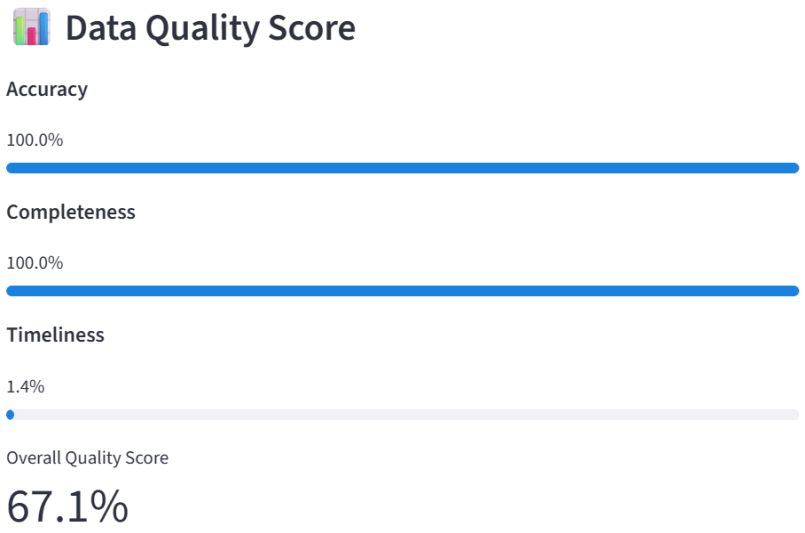

- Akurasi 100& karena tidak ada missing value setelah melalui cleaning data
- Semua sel data terisi penih

- Akan tetapi, untuk *timeliness* atau keterkinian data, menunjukkan hasil yang kurang baik. Hal ini dikarenakan data distribusi yang kurang merata, terutama pada bulan juli ke agustus yang jumlahnya sangat sedikit jika dibandingkan dengan bulan lain sementara perhitungan *timeliness* dilihat dari data 30 hari terakhir.

Overall Quality Score yaitu 67,1% sudah cukup baik, diluar dari hasil *timeliness* Sementara akurasi dan kelengkapan sudah mencapai 100%

G. GITHUB & STREAMLIT

a. Link Github

Ranianur21/data-lifecycle-smart-farming-23082010134

b. Link Streamlit

Smart Farming Dashboard · Streamlit